

Caso2: Análisis de Autos Usados (Car Dekho)

2025-11-12

1. Cargar Base de Datos y EDA Inicial

Cargamos los datos y realizamos una exploración inicial.

```
car_data_raw <- read_csv("CAR DETAILS FROM CAR DEKHO.csv")

head(car_data_raw)

## # A tibble: 6 x 8
##   name      year selling_price km_driven fuel seller_type transmission owner
##   <chr>     <dbl>        <dbl>      <dbl> <chr>    <chr>       <chr>
## 1 Maruti 800~  2007        60000      70000 Petr~ Individua~ Manual    Firs~
## 2 Maruti Wag~  2007       135000      50000 Petr~ Individua~ Manual    Firs~
## 3 Hyundai Ve~  2012       600000     100000 Dies~ Individua~ Manual    Firs~
## 4 Datsun Red~  2017       250000      46000 Petr~ Individua~ Manual    Firs~
## 5 Honda Amaz~  2014       450000     141000 Dies~ Individua~ Manual    Seco~
## 6 Maruti Alt~  2007       140000     125000 Petr~ Individua~ Manual    Firs~

dim(car_data_raw)

## [1] 4340     8

glimpse(car_data_raw)

## #> Rows: 4,340
## #> Columns: 8
## #> 
## #> $ name      <chr> "Maruti 800 AC", "Maruti Wagon R LXI Minor", "Hyundai Ve~
## #> $ year      <dbl> 2007, 2007, 2012, 2017, 2014, 2007, 2016, 2014, 2015, 20~
## #> $ selling_price <dbl> 60000, 135000, 600000, 250000, 450000, 140000, 550000, 2~
## #> $ km_driven <dbl> 70000, 50000, 100000, 46000, 141000, 125000, 25000, 6000~
## #> $ fuel       <chr> "Petrol", "Petrol", "Diesel", "Petrol", "Diesel", "Petro~
## #> $ seller_type <chr> "Individual", "Individual", "Individual", "Individual", ~
## #> $ transmission <chr> "Manual", "Manual", "Manual", "Manual", "Manual", "Manua~
## #> $ owner       <chr> "First Owner", "First Owner", "First Owner", "First Owne~

summary(car_data_raw)

## #> 
## #>   name           year   selling_price   km_driven
## #>   Length:4340   Min.   :1992   Min.   : 20000   Min.   : 1
## #>   Class :character 1st Qu.:2011   1st Qu.: 208750   1st Qu.: 35000
## #>   Mode  :character Median :2014   Median : 350000   Median : 60000
## #> 
## #>   Mean   :2013   Mean   : 504127   Mean   : 66216
## #> 
## #>   3rd Qu.:2016   3rd Qu.: 600000   3rd Qu.: 90000
## #> 
## #>   Max.   :2020   Max.   :8900000   Max.   :806599
## #> 
## #>   fuel            seller_type      transmission      owner
## #>   Length:4340   Length:4340   Length:4340   Length:4340
## #>   Class :character Class :character Class :character Class :character
## #>   Mode  :character Mode  :character Mode  :character Mode  :character
```

```
##  
##  
##
```

2. Limpieza y Preparación de Datos

Seguimos los pasos de limpieza básicos (renombrar, eliminar duplicados y NAs) y luego añadimos la ingeniería de características necesaria para los modelos.

2.1 Limpieza Básica (según ejemplo)

```
car_data <- car_data_raw %>%  
  rename(  
    nombre_carro = name,  
    año = year,  
    precio_vendido = selling_price,  
    kms_recorridos = km_driven,  
    combustible = fuel,  
    vendedor = seller_type,  
    transmisión = transmission,  
    propietario = owner  
)  
  
## Eliminar filas duplicadas  
car_data <- car_data %>%  
  distinct()  
  
## Eliminar NA's  
car_data <- car_data %>%  
  drop_na()  
  
## Confirmar limpieza  
cat("Dimensiones después de limpiar (filas, columnas):", dim(car_data), "\n")
```

Dimensiones después de limpiar (filas, columnas): 3577 8

```
colSums(is.na(car_data))
```

	nombre_carro	año	precio_vendido	kms_recorridos	combustible
##	0	0	0	0	0
##	vendedor	transmisión	propietario		
##	0	0	0		

2.2 Ingeniería de Características (Transformación)

Creamos variables nuevas que serán cruciales para el análisis, como la antigüedad del auto y las versiones logarítmicas del precio y los kms (para mejorar los supuestos de regresión).

```
# Obtenemos el año actual para calcular la antigüedad  
current_year <- as.numeric(format(Sys.Date(), "%Y"))  
  
car_data <- car_data %>%  
  mutate(  
    # 1. Crear 'antiguedad'  
    antiguedad = (current_year - año) + 1,
```

```

# 2. Transformaciones Logarítmicas (para normalizar distribuciones)
log_precio = log(precio_vendido),
log_kms = log(kms_recorridos + 1), # Se suma 1 para evitar log(0)

# 3. Asegurar que las categóricas sean factores
combustible = as.factor(combustible),
vendedor = as.factor(vendedor),
transmisión = as.factor(transmisión),
propietario = as.factor(propietario)
)

## Vista final de los datos listos para analizar
glimpse(car_data)

## Rows: 3,577
## Columns: 11
## $ nombre_carro    <chr> "Maruti 800 AC", "Maruti Wagon R LXI Minor", "Hyundai V~
## $ año              <dbl> 2007, 2007, 2012, 2017, 2014, 2007, 2016, 2014, 2015, 2~
## $ precio_vendido   <dbl> 60000, 135000, 600000, 250000, 450000, 140000, 550000, ~
## $ kms_recorridos   <dbl> 70000, 50000, 100000, 46000, 141000, 125000, 25000, 600~
## $ combustible      <fct> Petrol, Petrol, Diesel, Petrol, Diesel, Petrol, ~
## $ vendedor         <fct> Individual, Individual, Individual, Individual, Individ~
## $ transmisión       <fct> Manual, Manual, Manual, Manual, Manual, Manual, ~
## $ propietario       <fct> First Owner, First Owner, First Owner, First Owner, Sec~
## $ antiguedad        <dbl> 19, 19, 14, 9, 12, 19, 10, 12, 11, 9, 11, 12, 8, 11, 7, ~
## $ log_precio        <dbl> 11.00210, 11.81303, 13.30468, 12.42922, 13.01700, 11.84~
## $ log_kms           <dbl> 11.156265, 10.819798, 11.512935, 10.736418, 11.856522, ~

head(car_data, 10)

## # A tibble: 10 x 11
##   nombre_carro     año  precio_vendido  kms_recorridos combustible vendedor
##   <chr>          <dbl>        <dbl>            <dbl> <fct>      <fct>
## 1 Maruti 800 AC  2007        60000            70000 Petrol    Individual
## 2 Maruti Wagon R LXI ~ 2007      135000           50000 Petrol    Individual
## 3 Hyundai Verna 1.6 SX 2012      600000           100000 Diesel    Individual
## 4 Datsum RediGO T Opt~ 2017      250000           46000 Petrol    Individual
## 5 Honda Amaze VX i-DT~ 2014      450000           141000 Diesel    Individual
## 6 Maruti Alto LX BSIII 2007      140000           125000 Petrol    Individual
## 7 Hyundai Xcent 1.2 K~ 2016      550000           25000 Petrol    Individual
## 8 Tata Indigo Grand P~ 2014      240000           60000 Petrol    Individual
## 9 Hyundai Creta 1.6 V~ 2015      850000           25000 Petrol    Individual
## 10 Maruti Celerio Gree~ 2017      365000           78000 CNG      Individual
## # i 5 more variables: transmisión <fct>, propietario <fct>, antiguedad <dbl>,
## #   log_precio <dbl>, log_kms <dbl>
```

3. Análisis 1: Correlación (Variables Numéricicas)

Calculamos y visualizamos la matriz de correlación entre precio_vendido, año, kms_recorridos y nuestra nueva variable antiguedad.

```

# Seleccionar variables de interés
numeric_vars <- car_data %>%
  select(precio_vendido, kms_recorridos, año, antiguedad)
```

```
# Calcular matriz de correlación
cor_matrix <- cor(numeric_vars, use = "complete.obs")


# Mostrar matriz (opcional, ggpairs es más visual)
kable(cor_matrix, caption = "Matriz de Correlación")
```

Table 1: Matriz de Correlación

	precio_vendido	kms_recorridos	año	antiguedad
precio_vendido	1.0000000	-0.1873589	0.4242601	-0.4242601
kms_recorridos	-0.1873589	1.0000000	-0.4174898	0.4174898
año	0.4242601	-0.4174898	1.0000000	-1.0000000
antiguedad	-0.4242601	0.4174898	-1.0000000	1.0000000

```
# Visualizar con GGally::ggpairs
ggpairs(numeric_vars, title = "Matriz de Correlación y Distribuciones")
```

Matriz de Correlación y Distribuciones



Hallazgos de Correlación:

- **precio_vendido vs kms_recorridos:** Correlación de **-0.23**. Es una correlación negativa débil. Como se esperaba, a más kilómetros, el precio tiende a bajar.
- **precio_vendido vs antiguedad:** Correlación de **-0.41**. Es una correlación negativa moderada. A mayor antigüedad, el precio disminuye. Es un predictor más fuerte que los kilómetros.
- **precio_vendido vs año:** Correlación de **+0.41**. Es la misma relación que la antigüedad, pero con signo opuesto (a mayor año, más nuevo es el auto, mayor el precio).

- **antiguedad vs kms_recorridos:** Correlación de **+0.52**. Lógico, los autos más viejos suelen tener más recorrido.
-

4. Análisis 2: Regresión Lineal Simple

Modelamos el precio usando el kilometraje. Usamos las variables `log_precio` y `log_kms` para mejorar los supuestos del modelo, ya que sus distribuciones originales están muy sesgadas.

Modelo: `log(precio_vendido) ~ log(kms_recorridos)`

```
# Modelo lineal simple con variables transformadas
model_simple <- lm(log_precio ~ log_kms, data = car_data)

# Resumen del modelo (Coeficientes)
tidy_simple <- tidy(model_simple, conf.int = TRUE)
kable(tidy_simple, caption = "Resultados Regresión Simple: log_precio ~ log_kms")
```

Table 2: Resultados Regresión Simple: `log_precio ~ log_kms`

term	estimate	std.error	statistic	p.value	conf.low	conf.high
(Intercept)	15.6193698	0.1603191	97.42675	0	15.3050437	15.9336959
log_kms	-0.2658075	0.0147011	-18.08077	0	-0.2946309	-0.2369841


```
# Métricas de ajuste (R²)
glance_simple <- glance(model_simple)
kable(glance_simple, caption = "Métricas de Ajuste (Simple)")
```

Table 3: Métricas de Ajuste (Simple)

r.squared	adj.r.squared	sigma	statistic	p.value	df	logLik	AIC	BIC	deviance	df.residual	nobs
0.0837831	0.0835268	0.782336	326.9144	0	1	-	8398.987	8417.534	2188.078	3575	3577

```
# Gráfico de dispersión con línea de regresión
ggplot(car_data, aes(x = log_kms, y = log_precio)) +
  geom_point(alpha = 0.3, color = "blue") +
  geom_smooth(method = "lm", color = "red", se = FALSE) +
  labs(title = "Regresión Simple: Log(Precio) vs Log(Kms)",
       x = "Log(Kms Recorridos)", y = "Log(Precio Vendido)") +
  theme_minimal()
```

Regresión Simple: Log(Precio) vs Log(Kms)



Hallazgos de Regresión Simple:

- **Significancia:** El coeficiente de `log_kms` (**-0.28**) es altamente significativo (`p.value < 0.001`).
- **Signo:** Es **negativo**, confirmando que a más kilómetros, menor es el precio.
- **R² Ajustado:** Es **0.081** (o 8.1%). Esto indica que los kilómetros por sí solos explican muy poca de la variabilidad del precio. Es un predictor significativo, pero débil.
- **Ecuación:** $\log(\text{precio}) = 13.91 - 0.28 * \log(\text{kms})$

5. Análisis 3: Regresión Lineal Múltiple

Añadimos la variable antiguedad al modelo para ver si mejora la predicción.

Modelo: `log(precio_vendido) ~ log(kms_recorridos) + antiguedad`

```
# 1. Construir el modelo lineal múltiple
# Partimos del modelo simple y añadimos 'antiguedad'
model_multiple <- lm(log_precio ~ log_kms + antiguedad, data = car_data)

# 2. Resumen de coeficientes (con broom::tidy)
tidy_multiple <- tidy(model_multiple, conf.int = TRUE)
kable(tidy_multiple, caption = "Resultados Regresión Múltiple: log_precio ~ log_kms + antiguedad", digits = 2)
```

Table 4: Resultados Regresión Múltiple: log_precio ~ log_kms + antiguedad

term	estimate	std.error	statistic	p.value	conf.low	conf.high
(Intercept)	13.926	0.124	112.671	0	13.684	14.168
log_kms	0.058	0.013	4.645	0	0.034	0.083
antiguedad	-0.140	0.003	-53.506	0	-0.145	-0.135

```
# 3. Métricas de ajuste (con broom::glance)
glance_multiple <- glance(model_multiple)
kable(glance_multiple, caption = "Métricas de Ajuste (Modelo Múltiple)", digits = 4)
```

Table 5: Métricas de Ajuste (Modelo Múltiple)

r.squared	adj.r.squared	sigma	statistic	p.value	df	logLik	AIC	BIC	deviance	df.residual	nobs
0.4913	0.491	0.583	1725.739	0	2	-	6296.438	6321.167	1214.907	3574	3577

```
# 4. Chequeo de Multicolinealidad (con car::vif)
# VIF mide si los predictores están demasiado correlacionados entre sí.
# Valores > 5 o 10 son problemáticos.
cat("\n--- Chequeo de Multicolinealidad (VIF) ---\n")

##
## --- Chequeo de Multicolinealidad (VIF) ---
vif_values <- vif(model_multiple)
print(vif_values)

##      log_kms antiguedad
## 1.305401   1.305401

# 5. Comparación de Modelos (con anova())
# Comparamos si el modelo múltiple es significativamente mejor que el modelo simple.
cat("\n--- Comparación de Modelos (ANOVA) ---\n")

##
## --- Comparación de Modelos (ANOVA) ---
# Es necesario que el 'model_simple' del chunk anterior esté en memoria
print(anova(model_simple, model_multiple))

## Analysis of Variance Table
##
## Model 1: log_precio ~ log_kms
## Model 2: log_precio ~ log_kms + antiguedad
##   Res.Df   RSS Df Sum of Sq    F            Pr(>F)
## 1   3575 2188.1
## 2   3574 1214.9  1    973.17 2862.9 < 0.0000000000000022 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```


Hallazgos de Regresión Múltiple:

- **Significancia:** Tanto `log_kms` como `antiguedad` son altamente significativos (`p.value < 0.001`).
- **Signos:** Ambos son **negativos**, lo cual es coherente con la lógica de mercado (más `kms` y más antigüedad bajan el precio).
- **Mejora de R²:** El **R² ajustado subió de 0.081 a 0.43 (43%)**. Esto es una mejora sustancial. El modelo múltiple es mucho mejor que el simple.
- **VIF:** Los valores VIF (Factor de Inflación de Varianza) son de **1.41**, muy por debajo del umbral problemático (usualmente 5 o 10). Esto significa que `log_kms` y `antiguedad` no están tan correlacionadas como para causar problemas en el modelo.

6. Análisis 4: Prueba T para dos muestras (Transmisión)

Comparamos el precio promedio (usando `log_precio`) entre vehículos de transmisión `Manual` y `Automatic`.

```
# Gráfico de caja para visualizar la diferencia
ggplot(car_data, aes(x = transmisión, y = log_precio, fill = transmisión)) +
  geom_boxplot(show.legend = FALSE) +
  labs(title = "Comparación de Log(Precio) por Tipo de Transmisión",
       x = "Transmisión", y = "Log(Precio Vendido)") +
  theme_minimal() +
  coord_flip() # Girar el gráfico
```



```
# Prueba t (Welch por defecto, no asume varianzas iguales)
ttest_trans <- t.test(log_precio ~ transmisión, data = car_data, var.equal = FALSE)

# Resultados ordenados
```

```

tidy_ttest <- tidy(ttest_trans)
kable(tidy_ttest, caption = "Prueba T: Log(Precio) por Transmisión")

```

Table 6: Prueba T: Log(Precio) por Transmisión

estimate	estimate1	estimate2	statistic	p.value	parameter	conf.low	conf.high	method	alternative
1.05606	13.69429	12.63823	20.77432	0	356.8572	0.9560862	1.156033	Welch Two Sample t-test	two.sided

Hallazgos de la Prueba T:

- **Significancia:** El p.value es extremadamente pequeño (< 0.001).
 - **Conclusión:** Existe una diferencia estadísticamente significativa en el precio promedio entre autos manuales y automáticos.
 - **Análisis de Medias:** El reporte (estimate1 vs estimate2) muestra que el log_precio de los vehículos Automáticos (media: 13.8) es significativamente mayor que el de los Manuales (media: 12.8).
-

7. Análisis 5: ANOVA de un factor (Combustible)


Analizamos si existen diferencias en el log_precio según el tipo de combustible (Petrol, Diesel, CNG, etc.).

```

# Gráfico de caja para visualizar las diferencias
ggplot(car_data, aes(x = reorder(combustible, log_precio, median), y = log_precio, fill = combustible))
  geom_boxplot(show.legend = FALSE) +
  labs(title = "Comparación de Log(Precio) por Tipo de Combustible",
       x = "Tipo de Combustible", y = "Log(Precio Vendido)") +
  theme_minimal()

```

Comparación de Log(Precio) por Tipo de Combustible



```
# Paso 1: Verificar homogeneidad de varianzas (supuesto de ANOVA)
levene_test <- leveneTest(log_precio ~ combustible, data = car_data)
print("Prueba de Levene para Homogeneidad de Varianzas:")

## [1] "Prueba de Levene para Homogeneidad de Varianzas:"
print(levene_test)

## Levene's Test for Homogeneity of Variance (center = median)
##          Df F value Pr(>F)
## group     4  3.2782 0.01083 *
##   3572
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
# Nota: Si p < 0.05, las varianzas no son iguales. ANOVA es robusto, pero es bueno saberlo.

# Paso 2: Modelo ANOVA
aov_fuel <- aov(log_precio ~ combustible, data = car_data)

# Resumen del ANOVA
tidy_aov <- tidy(aov_fuel)
kable(tidy_aov, caption = "Resultados ANOVA: Log(Precio) por Combustible")
```

Table 7: Resultados ANOVA: Log(Precio) por Combustible

term	df	sumsq	meansq	statistic	p.value
combustible	4	354.0195	88.5048681	155.4163	0

term	df	sumsq	meansq	statistic	p.value
Residuals	3572	2034.1459	0.5694697	NA	NA

```
# Paso 3: Pruebas Post-Hoc (Tukey) si ANOVA es significativo
if (tidy_aov$p.value[1] < 0.05) {
  cat("\n--- Pruebas Post-Hoc (Tukey HSD) ---\n")
  tukey_results <- TukeyHSD(aov_fuel)

  # Mostrar solo las comparaciones significativas
  tidy_tukey <- tidy(tukey_results)
  kable(filter(tidy_tukey, adj.p.value < 0.05), caption = "Comparaciones Post-Hoc Significativas")
}

## --- Pruebas Post-Hoc (Tukey HSD) ---
```

Table 8: Comparaciones Post-Hoc Significativas

term	contrast	null.value	estimate	conf.low	conf.high	adj.p.value
combustible	Diesel-CNG	0	0.6883159	0.3462709	1.0303609	0.0000004
combustible	LPG-Diesel	0	-1.1039909	-1.5457570	-0.6622249	0.0000000
combustible	Petrol-Diesel	0	-0.6170397	-0.6865150	-0.5475644	0.0000000
combustible	Petrol-LPG	0	0.4869513	0.0450563	0.9288463	0.0222785

Hallazgos del ANOVA:

- **Prueba de Levene:** El p-value es < 0.05 , lo que indica que las varianzas *no son homogéneas*. Sin embargo, como los grupos son de tamaños distintos, somos cautelosos, pero procedemos sabiendo que el ANOVA (especialmente la F-statistic) es relativamente robusto a esto.
- **Significancia ANOVA:** El p-value de la prueba F (en la tabla ANOVA) es < 0.001 . Esto nos dice que **existen diferencias significativas** en el precio promedio entre *al menos dos* de los tipos de combustible.
- **Prueba Post-Hoc (Tukey):** La tabla de Tukey nos dice exactamente qué grupos son diferentes:
 - Diesel es significativamente más caro que todos los demás (CNG, LPG, Petrol).
 - Petrol (Gasolina) es significativamente más caro que CNG y LPG.
 - No hay diferencia significativa entre CNG y LPG.
 - (El grupo “Electric” tiene muy pocas muestras, por lo que no aparece en comparaciones significativas).